

Комплексный подход к формальной верификации систем искусственного интеллекта, основанных на нейронных сетях

Кондратьев Дмитрий Александрович
apple-66@mail.ru

Институт систем информатики им. А. П. Ершова СО РАН

Проблема: надежность и корректность гибридных интеллектуальных систем

В настоящее время искусственный интеллект, основанный на нейронных сетях, стал активно применяться в программном обеспечении таких систем, к надежности и корректности которых предъявляются повышенные требования (например, беспилотные транспортные системы).

Известно, что тестирование не может гарантировать корректность и надежность программного обеспечения.

Следовательно, тестирование не может гарантировать корректность и надежность такого программного обеспечения, которое реализует искусственный интеллект.

Гарантировать корректность и надежности программного обеспечения может только формальная верификация программ.

Формальная верификация программ


Входными данными формальной верификации являются программа и ее спецификации, описывающие те свойства программы, выполнение которых нужно проверить.

Формальная верификация позволяет доказать, что программа корректна относительно своих спецификаций.

Для проверки корректности программы относительно формальных спецификаций, описывающих результат или процесс ее исполнения, применяется такой вид формальной верификации, как дедуктивная верификация.


Дедуктивная верификация нейронных сетей

Дедуктивная верификация может гарантировать, что нейронная сеть удовлетворяет спецификации, описывающей связь входных и выходных данных. Рассмотрим схему дедуктивной верификации нейронных сетей:



На пути к умному транспорту: обзор статьи о роботе

Amir G., Corsi D., Yerushalmi R., Marzari L., Harel D., Farinelli A., Katz G.
Verifying Learning-Based Robotic Navigation Systems // Lecture Notes in
Computer Science. 2023. Volume 13993. pp. 607–627.



Робот движется к цели (известны угол и расстояние). Робот управляется командами: вперед, повернуть вправо на 30^0 и повернуть влево на 30^0 . У робота 7 лидаров для измерения расстояния до препятствий в 7 направлениях. Нейронная сеть выдает команду роботу.

Формальное описание верифицируемых свойств

Входы нейронной сети:

- x_i for $i = [0, 1, 2, 3, 4, 5, 6]$ – расстояние до препятствий по данным семи лидаров.
- x_7 – угол до цели.
- x_8 – расстояние до цели.

Все входы нейронной сети нормализованы, т.е.

$$x_i \in [0, 1] \text{ for } i = [0, 1, 2, 3, 4, 5, 6, 7, 8]$$

Выходы нейронной сети:

- y_0 – движение вперед.
- y_1 – движение налево.
- y_2 – движение направо.

В качестве команды для движения выбирается наибольший по значению выход нейронной сети.

Формальное описание верифицируемых свойств

Свойство, что будет столкновение при движении вперед из-за слишком близкого препятствия спереди.

Если расстояние до препятствия спереди не превосходит 0.185 и выработана команда для движения робота вперед, то робот столкнется с препятствием.

Предусловие (P):

$$x_i \in [0.2, 1] \text{ for } i = [0, 1, 2, 4, 5, 6] \wedge \\ x_3 \in [0.135, 0.185] \wedge x_7 \in [0, 1] \wedge x_8 \in [0.2, 1]$$

Постусловие (Q):

$$y_0 > y_1 \wedge y_0 > y_2$$

Актуальность формальной верификации нейронных сетей

С помощью методов обучения с подкреплением были обучены 780 нейронных сетей для управления таким роботом. Из них для 778 нейронных сетей были найдены контрпримеры к как минимум одному свойству.

Итого, методы обучения с подкреплением не позволяют получить корректные по построению нейронные сети.

Еще одно подтверждение важности формальной верификации нейронных сетей – верификаций нейронной сети для системы ACAS Xu предупреждения опасного сближения самолетов:

Katz G., Barrett C., Dill D.L., Julian K., Kochenderfer M.J. Reluplex: An Efficient SMT Solver for Verifying Deep Neural Networks // Lecture Notes in Computer Science. 2017. Volume 10426. pp. 97-117. DOI: https://doi.org/10.1007/978-3-319-63387-9_5

Свойство состоятельности устойчивости

Обзор статьи о нейросимволическом подходе к дедуктивной верификации искусственного интеллекта:

Xie X., Kersting K., Neider D. Neuro-Symbolic Verification of Deep Neural Networks. 2022. DOI: <https://doi.org/10.48550/arXiv.2203.00938>

Необходимо доказать, что нейронная сеть устойчива к небольшим изменениям входных данных (т. е. небольшие изменения входных данных не меняют выходные данные). Чтобы сделать это математически точно, предположим, что нам дана многоклассовая нейронная сеть $f: \mathbb{R}^m \rightarrow \{c_1, \dots, c_n\}$ с m признаками и n классами, конкретным входом $\vec{x}^* \in \mathbb{R}^m$, функция расстояния $d: \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}_+$, и расстояние $\varepsilon \geq 0$. Тогда задача — доказать, что

$$d(\vec{x}^*, \vec{x}) \leq \varepsilon \text{ implies } f(\vec{x}^*) = f(\vec{x})$$

для всех входных данных $\vec{x} \in \mathbb{R}^m$. Вход $\vec{x} \in \mathbb{R}^m$, нарушающий свойство состоятельности устойчивости, называется состоятельным примером.

Обзор статьи о нейросимволическом подходе к дедуктивной верификации искусственного интеллекта

Xie X., Kersting K., Neider D. Neuro-Symbolic Verification of Deep Neural Networks. 2022. DOI:

<https://doi.org/10.48550/arXiv.2203.00938>

В данной статье описан подход к дедуктивной верификации нейронных сетей. Данный подход назван нейросимволическим подходом.

В целях дедуктивной верификации рассмотрим нейронную сеть $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ как расширенный граф $G_f = (V, V_I, V_O, E, \alpha)$, где

- V — конечное множество вершин (т.е., нейронов),
- V_I являются входными нейронами,
- V_O являются выходными нейронами ($V_I \cap V_O = \emptyset$),
- $E \subseteq V \times \mathbb{R} \times V$ — отношение для дуг с весами,
- α является отображением, назначающим функцию активации (например, ReLU, сигмоид, и д.р.) каждому нейрону в $V \setminus V_I$.

Обзор статьи о нейросимволическом подходе к дедуктивной верификации искусственного интеллекта

Тройка Хоара с нейронной сетью

$$P := \{ \varphi_{pre}(\vec{x}) \} \varphi_{assign}(\vec{x}, \vec{y}) \{ \varphi_{post}(\vec{x}, \vec{y}) \},$$

где

- $\vec{x} = (x_1, \dots, x_m)$,
- $\vec{y} = (y_1, \dots, y_n)$,
- $\varphi_{assign}(\vec{x}, \vec{y}) := \vec{y} \leftarrow f(\vec{x})$,
- $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ — нейронная сеть,
- $G_f = (V, V_I, V_O, E, \alpha)$ — графовое представление f .

Далее будем определять правило вывода для тройки Хоара с нейронной сетью

Обзор статьи о нейросимволическом подходе к дедуктивной верификации искусственного интеллекта

Пусть выходному значению каждого нейрона $v \in V$ соответствует переменная X_v . Тогда каждому нейрону (кроме входных) соответствует формула φ_v :

$$\varphi_v := X_v = \alpha(v) \left(\sum_{(v', w, v) \in E} w \cdot X_{v'} \right),$$

В случае такой функции активации, как ReLU, зададим φ_v с помощью вспомогательной переменной Y_v :

$$\left(Y_v = \sum_{(v', w, v) \in E} w \cdot X_{v'} \right) \wedge \left((Y_v \leq 0 \rightarrow X_v = 0) \wedge (Y_v > 0 \rightarrow X_v = Y_v) \right),$$

Обзор статьи о нейросимволическом подходе к дедуктивной верификации искусственного интеллекта

Формула, соответствующая всей нейронной сети:

$$\varphi_f := \bigwedge_{v \in V \setminus V_I} \varphi_v$$

Правило вывода, задающее формальную семантику нейронной сети:

$$\frac{(\varphi_{pre}[\vec{x} / \vec{X}_{V_I}] \wedge \varphi_f) \rightarrow \varphi_{post}[\vec{x} / \vec{X}_{V_I}, \vec{y} / \vec{X}_{V_O}]}{\left\{ \varphi_{pre}(\vec{x}) \right\} \vec{y} \leftarrow f(\vec{x}) \left\{ \varphi_{post}(\vec{x}, \vec{y}) \right\}}$$

где $\varphi[\vec{z}_1 / \vec{z}_2]$ обозначает результат замены в φ вектора переменных z_1 на z_2 .

Условие корректности нейронной сети:

$$\psi := (\varphi_{pre}[\vec{x} / \vec{X}_{V_I}] \wedge \varphi_f) \rightarrow \varphi_{post}[\vec{x} / \vec{X}_{V_I}, \vec{y} / \vec{X}_{V_O}],$$

Программная система Marabou

Интерфейс SMT-решателя (sat (примеры), unsat, unknown).
Контрпримеры, когда отрицание формулы и sat.

В основе решение задачи линейного программирования с помощью Simplex-алгоритма.

Основная проблема для линейного программирования в случае нейронных сетей: наличие ReLU добавляет в формулу нелинейную компоненту, что серьезно усложняет доказательство.

На пути к решению проблемы вызванной ReLU нелинейности: для каждого узла нейронной сети рассмотреть два случая: активирован или не активирован. Но тогда получается слишком много случаев.

Основная идея Marabou: использовать вариант Simplex-алгоритма.

Обзор статьи об оптимизации нейронных сетей с помощью формальной верификации

Gokulanathan S., Feldsher A., Malca A., Barrett C., Katz G. Simplifying Neural Networks Using Formal Verification // Lecture Notes in Computer Science. 2020. Volume 12229. pp. 85-93. DOI: https://doi.org/10.1007/978-3-030-55754-6_5

Если при всех входных данных нейронной сети значение выхода нейрона либо равно нулю, то такой нейрон можно элиминировать. Условие ненужности i -того нейрона в нейронной сети:

$$\varphi_i \rightarrow (X_{V_i} = 0), \text{ где}$$

- X_{V_i} – формула, соответствующая i -тому узлу нейронной сети.
- φ_i – конъюнкция формул, соответствующих всем узлам на пути к данному узлу нейронной сети.

Если такое условие истинно, то такой нейрон можно удалить из нейронной сети. В результате удаления нейрона получаем увеличение скорости вычисления нейронной сети.

Недостатки и достоинства родственных работ

Недостатки родственных работ:

- Исследования в начальной стадии
- Разрозненные исследования
- Применимость пока что только к относительно небольшим нейронным сетям

Достоинства родственных работ:

- Актуальность тематики
- Важная с точки зрения обеспечения надежности сфера Edge AI
- Важная с точки зрения обеспечения надежности сфера tinyML

Созданный в ИСИ СО РАН задел для исследования по формальной верификации нейронных сетей

- **Метод смешанной аксиоматической семантики**
- **Методы автоматизации доказательства условий корректности**
- **Методы локализации ошибок при формальной верификации**
- **Онтологический подход к заданию семантик языков программирования с помощью языка ABML**

Методы автоматизации доказательства условий корректности

Проблема автоматизации доказательства условий корректности

Предложен набор стратегий автоматизации доказательства условий корректности

Эти стратегии в основном используют генерацию лемм

Kondratyev D., Promsky A. Proof Strategy for Automated Sisal Program Verification // Lecture Notes in Computer Science. 2019. Volume 11771. pp. 113–120. DOI: https://doi.org/10.1007/978-3-030-29852-4_9

Методы локализации ошибок при формальной верификации

Проблема локализации ошибок

Стратегии для анализа недоказанных условий корректности

Kondratyev D.A., Promsky A.V. The Complex Approach of the C-lightVer System to the Automated Error Localization in C Programs // Automatic Control and Computer Sciences. 2020. Volume 54. Issue 7. pp. 728–739. DOI: <https://doi.org/10.3103/S0146411620070093>

Созданный в ИСИ СО РАН задел для исследования по формальной верификации нейронных сетей

За создание этого задела и его реализацию в системе C-lightVer Кондратьев Д.А. был награжден Почетной грамотой СО РАН за второе место на конкурсе по присуждению премий имени выдающихся ученых СО РАН за цикл работ "Комплексный подход к автоматизации дедуктивной верификации программ с финитными итерациями", представленных на премию имени А.П. Ершова – за работы в области информатики, теории и автоматизации программирования.

Постановление Президиума СО РАН №343 от 03.10.2024.

Основная статья с описанием комплексного подхода:

Kondratyev D.A., Nepomniaschy V.A. Automation of C Program Deductive Verification without Using Loop Invariants // Programming and Computer Software. 2022. Volume 48. Issue 5. pp. 331–346. DOI: <https://doi.org/10.1134/S036176882205005X>

Метод смешанной аксиоматической семантики

Проблема упрощения условий корректности

Метод основан на использовании семантики, зависящей от контекста

Maryasov I.V., Nepomniaschy V.A., Promsky A.V., Kondratyev D.A.
Automatic C Program Verification Based on Mixed Axiomatic Semantics
// Automatic Control and Computer Sciences. 2014. Volume 48. Issue 7.
pp. 407–414. DOI: <https://doi.org/10.3103/S0146411614070141>

Онтологический подход к заданию семантик языков программирования с помощью языка ABML

Язык ABML позволяет относительно просто реализовать наши методы, используя предоставляемую онтологиями гибкость

Ануреев И.С., Гаранина Н.О., Кондратьев Д.А., Горлач С.П.
Построение операционной семантики языков программирования в виде исполняемых онтологических моделей программ // Моделирование и анализ информационных систем. 2026. Т. 33. № 2. С. 122–149. DOI: <https://doi.org/10.18255/1818-1015-2026-2-122-149>

Исследование по формальной верификации нейронных сетей

Цель исследования состоит в разработке комплексного подхода к формальной верификации систем искусственного интеллекта на основе нейронных сетей.

Задачи исследования:

- Проверка различных свойств систем на основе нейронных сетей, в том числе заданных пользователями свойств.
- Поиск контрпримеров к проверяемым свойствам.
- Оптимизация нейронных сетей на основе проверки свойства об отсутствии влияния отдельных частей нейронной сети на всю сеть.
- Реализация данного комплексного подхода в программной системе NeuroVer для формальной верификации нейронных сетей.

Научная новизна исследования состоит в решении нескольких задач формальной верификации нейронных сетей с помощью единого комплексного подхода.

Комплексный подход: базовые свойства

Особенность базовых свойств состоит в том, что они связывают между собой данные из обучающей выборки и результаты применения нейронной сети.

- Свойство состязательной устойчивости относительно центра кластера выборки
- Свойство расстояния до центра кластера выборки

Свойство состязательной устойчивости относительно центра кластера выборки


Свойство состязательной устойчивости относительно центра кластера выборки состоит в том, что все нормализованные входные данные, расстояние от которых до данного центра меньше константы ϵ , классифицируются нейронной сетью в этом же кластере. Данное свойство проверяется только в том случае, если центр кластера выборки принадлежит этому кластеру.

- Свойство состязательной устойчивости относительно центра кластера обучающей выборки
- Свойство состязательной устойчивости относительно центра кластера тестовой выборки

Свойство расстояния до центра кластера выборки

Свойство расстояния до центра кластера выборки состоит в том, что для любого нормализованного входного данного, если нейронная сеть классифицирует это данное в определенном кластере, то расстояние от данного центра до этого входного данного меньше константы ϵ . Данное свойство, в отличие от свойства связательной устойчивости относительно центра кластера выборки, не требует, чтобы все данные, расстояние от которых до центра кластера выборки меньше ϵ , попадали в этот кластер.

Сравнение свойства связательной устойчивости относительно центра кластера обучающей выборки со свойством расстояния до центра кластера выборки



Комплексный подход: правила вывода условий корректности нейронных сетей

Правила, позволяющие выводить более простые условия корректности в частных случаях, чем условия корректности в общем случае.

Комплексный подход: методы доказательства условий корректности нейронных сетей и методы поиска контрпримеров к свойствам нейронной сети

- стратегии для нелинейной арифметики над вещественными числами;
- стратегии для сведения задачи к линейному программированию.

Комплексный подход: оптимизация нейронных сетей на основе проверки свойства об отсутствии влияния отдельных частей нейронной сети на всю сеть

Задание свойств об отсутствии влияния отдельных частей нейронной сети на всю сеть.

Пример: проект DIANNA

Нейронная сеть для определения сезона года:

Oostrum, L., & Yang, L. (2023). ONNX model trained on weather prediction dataset. Zenodo. <https://doi.org/10.5281/zenodo.7543883>

Эта нейронная сеть используется для проверки возможностей проекта DIANNA по объяснимому искусственному интеллекту:

Elena Rangelova et al. 2022. DIANNA: Deep Insight And Neural Network Analysis. Journal of Open Source Software, 7(80), 4493.
<https://doi.org/10.21105/joss.04493>

Эта нейронная сеть обучена на наборе погодных данных:

Huber, F. (2021). Weather prediction dataset (Version v3) [Data set]. Zenodo. <https://doi.org/10.5281/zenodo.5071376>

Этот набор погодных данных описан в исследовании:

Klein Tank, A.M.G. et al., 2002. Daily dataset of 20th-century surface air temperature and precipitation series for the European Climate Assessment. Int. J. of Climatol., 22, 1441-1453.

Пример: погодная нейронная сеть

Данная нейронная сеть принимает на вход данные за 28 дней:

- Облачность
- Влажность
- Давление
- Уровень солнечного излучения
- Уровень осадков
- Уровень солнечного света
- Средняя температура за день
- Минимальная температура за день
- Максимальная температура за день

У нейронной сети четыре выхода – вероятности, что входные данные относятся к тому или иному сезону. Эти вероятности получены с помощью применения на последнем слое softmax – в ходе экспериментов обнаружено, что из-за монотонности softmax этот слой можно для упрощения верификации не учитывать и рассматривать максимальное число среди выходов, указывающих на сезон.

Перспективы

Ближайшие планы: формальная верификация довольно малых по количеству параметров (380 параметров) нейродатчиков, применяемых, например, для анализа ЭКГ и описанных в <https://habr.com/ru/articles/990552/>

Дальнейшие направления исследования:

- Исследование формальной семантики искусственного интеллекта
- Доверенный искусственный интеллект на основе формальной верификации
- Гарантированные свойства искусственного интеллекта