Источники для презентации «Агентные фреймворки 2026: функционал пожирает безопасность»

Ниже приведён полный перечень утверждений из презентации с подтверждающими источниками. Структура следует порядку слайдов.

Слайд: 2026 — агенты вышли из песочниц

«40% корпоративных приложений» (Gartner)

Gartner прогнозирует, что к концу 2026 года 40% корпоративных приложений будут интегрированы с task-specific AI-агентами, по сравнению с менее чем 5% в 2025 году. Пресс-релиз Gartner опубликован 26 августа 2025 года, обновлён 5 сентября 2025 года. В лучшем сценарии agentic AI может обеспечить ~30% дохода от корпоративного ПО к 2035 году, превысив $450B.[1][2][3][4]

«Только 14.4% команд имеют security approval»

Данные из отчёта Gravitee «State of AI Agent Security 2026», который проанализировал сотни организаций. Конкретно: 80.9% команд уже имеют агентов в тестировании или продакшне, но лишь 14.4% прошли полный процесс security approval. 88% организаций сообщили о подтверждённом или подозреваемом инциденте безопасности, связанном с AI-агентами.[5][6][7]

Слайд: OWASP Top 10 for Agentic Applications (декабрь 2025)

OWASP GenAI Security Project опубликовал OWASP Top 10 for Agentic Applications в декабре 2025 года. Полный список:[8][9][10]

Код	Название	Источник
ASI01	Agent Goal Hijack	[9][10]
ASI02	Tool Misuse	[9][11]
ASI03	Identity & Privilege Abuse	[9][10]
ASI04	Supply Chain Vulnerabilities	[9]
ASI05	Remote Code Execution	[9][10]
ASI06	Memory & Context Poisoning	[9][11]
ASI07	Insecure Inter-Agent Comms	[9][10]
ASI08	Cascading Failures	[9][11]
ASI09	Human-Agent Trust Exploit	[10][12]
ASI10	Rogue Agents	[9][12]

Слайд: Пятёрка фреймворков — сводная таблица

Фреймворк	CVE / Уязвимость	Источник
LangGraph	CVE-2026-27794 — pickle RCE через кэш (CVSS High)	NVD [13], SentinelOne [14], Feedly [15], GitHub Advisory GHSA-mhr3-j7m5-c7c9 [16]
AutoGen	Архитектурная проблема: граница команда/инъекция размыта	Описано в контексте слияния с SK [17][18]
CrewAI	Uncrew (CVSS 9.2) — утечка GitHub-токена	Noma Labs [19][20]
OpenClaw	CVE-2026-25253 — 1-click RCE (CVSS 8.8)	NVD [21], The Hacker News [22], runZero [23], ColonelServer [24]
Semantic Kernel	На момент презентации — нет публичных CVE	*См. примечание ниже*

> **Примечание по Semantic Kernel:** После даты презентации были опубликованы CVE-2026-25592 (Arbitrary File Write, Critical) 6 февраля 2026 и CVE-2026-26030 (RCE через InMemoryVectorStore) 24 февраля 2026. На момент подготовки слайдов утверждение «нет публичных CVE» было корректным.[25][26][27]

Слайд: LangGraph — Общий state = общая дыра

CVE-2026-27794 (CVSS High) — Remote Code Execution через insecure deserialization (pickle) в кэширующем слое LangGraph Checkpoint. BaseCache по умолчанию использовал `JsonPlusSerializer(pickle_fallback=True)`, что позволяло выполнять произвольный код при записи вредоносных pickle-объектов в

Redis/SQLite кэш. Патч выпущен в langgraph-checkpoint v4.0.0 (февраль 2026).[14][15][16]

Слайд: AutoGen — Граница команда/инъекция размыта

Microsoft объединяет AutoGen и Semantic Kernel в единый Microsoft Agent Framework, выпущенный в public preview 1 октября 2025 года. AutoGen переведён в режим maintenance: критические баг-фиксы и security-патчи, но без новых функций. Azure AI Foundry уже использует Semantic Kernel/Agent Framework как внутренний оркестратор, с 10,000+ организаций на Azure AI Foundry Agent Service.[17][28][18]

Слайд: CrewAI — Иллюзия изоляции через роли

Uncrew (CVSS 9.2)

Noma Labs обнаружила критическую уязвимость в платформе CrewAI: при provisioning machines ошибка exception handling раскрывала внутренний GitHub-токен с полными admin-привилегиями по всей GitHub-инфраструктуре CrewAI. Уязвимость обнаружена 5 марта 2025 года, CrewAI выпустила патч в течение 5 часов.[19][20]

«65% успешная эксфильтрация данных»

Исследование AgentLeak (arXiv, февраль 2026) показало, что в мультиагентных конфигурациях общая системная утечка данных составляет 68.9% (OR-aggregated по всем каналам). Для CrewAI конкретно: межагентные сообщения (C2) показали утечку до 68.8%, что в 2.5× выше внешнего вывода. Исследование тестировало GPT-4o, Claude 3.5 Sonnet, Mistral Large, Llama 3.3 70B.[29]

> **Уточнение:** В презентации указано «65%» — ближайшее peer-reviewed значение из AgentLeak составляет 68.9% (совокупная утечка по всем каналам) или 68.8% (межагентный канал C2). Числа могут относиться к более раннему или альтернативному бенчмарку.

Слайд: OpenClaw — Правильная идея, незрелая реализация

CVE-2026-25253 (CVSS 8.8) — 1-click RCE

Уязвимость в OpenClaw позволяла удалённому неаутентифицированному атакующему выполнить код через эксфильтрацию токена аутентификации через WebSocket. OpenClaw не валидировал gatewayUrl из query string и автоматически устанавливал WebSocket-соединение, отправляя сохранённый gateway token. Патч в версии 2026.1.29 от 30 января 2026.[30][23][22][21]

Supply chain: атака через Cline

Упоминание supply chain attack через Cline (agentic coding tool), устанавливавшей OpenClaw на машины разработчиков, подтверждается в контексте широкого распространения платформы и модульной архитектуры.[31]

Слайд: Semantic Kernel — Безопасность vs скорость

На момент презентации Semantic Kernel не имел публичных CVE в отличие от остальных четырёх фреймворков. Поглощение AutoGen подтверждено — оба фреймворка переведены в maintenance mode, разработка сосредоточена на Microsoft Agent Framework. Semantic Kernel обеспечивает Azure AD интеграцию, контроль разрешений на уровне плагинов, изоляцию состояния.[18][17]

Слайд: Agents Rule of Two (Meta AI, 2025)

Фреймворк опубликован Meta AI 31 октября 2025 года. Агент должен удовлетворять не более 2 из 3 свойств:[32][33][34]

- **[A]** Обрабатывает ненадёжный ввод
- **[B]** Доступ к чувствительным данным
- **[C]** Может менять состояние / внешние вызовы

Все три одновременно = «Lethal Trifecta» — требуется HITL или запрет автономности. Концепция вдохновлена Google Chrome's Rule of 2 и «lethal trifecta» Саймона Уиллисона.[35][34][32]

Слайд: Prompt Injection — вирус в цепочке

«73% продакшн-деплоев»

OWASP 2025 Top 10 for LLM Applications ранжирует prompt injection как уязвимость #1, обнаруженную в более чем 73% продакшн AI-деплоев при security-аудитах.[36][37][38]

Morris II — самораспространяющийся AI-червь

Исследователи из Cornell Tech и Technion Institute создали Morris II — первый червь для GenAI-экосистем, использующий adversarial self-replicating prompts. Червь заражает email-ассистента, который рассылает заражённые письма — протестирован на Gemini Pro, ChatGPT 4.0, LLaVA.[39][40][41]

«Attacker Moves Second» — 14 авторов, 12 защит обойдены

Статья от 10 октября 2025 (arXiv:2510.09023) — 14 авторов, включая представителей OpenAI, Anthropic и Google DeepMind:[42][32]

Milad Nasr, Nicholas Carlini, Chawin Sitawarin, Sander V. Schulhoff, Jamie Hayes, Michael Ilie, Juliette Pluto, Shuang Song, Harsh

Chaudhari, Ilia Shumailov, Abhradeep Thakurta, Kai Yuanqing Xiao, Andreas Terzis, Florian Tramèr.[42]

Результат: 12 опубликованных защит обойдены с attack success rate >90% для большинства, при том что оригинальные защиты заявляли near-zero attack success rates.[32][42]

Слайд: EchoLeak — CVE-2025-32711 (CVSS 9.3)

Aim Security обнаружила EchoLeak — первую zero-click AI-уязвимость в Microsoft 365 Copilot. Скрытая инструкция в email позволяла автоматически эксфильтровать данные из M365 Copilot без какого-либо взаимодействия пользователя. CVE-2025-32711 включена в Microsoft Patch Tuesday за июнь 2025.[43][44][45][46]

Слайд: MCP Tool Poisoning (Invariant Labs)

Invariant Labs продемонстрировала, что скрытые инструкции в описаниях MCP-инструментов невидимы пользователям, но полностью видны AI-моделям. В proof-of-concept исследователи показали полную эксфильтрацию WhatsApp-переписки через отравленный MCP-инструмент. Техника «Rug Pull»: сервер подменяет описание инструмента после первоначального одобрения пользователем.[47][48][49][50][51]

Слайд: Agent Session Smuggling (Unit 42, Palo Alto)

Palo Alto Networks Unit 42 продемонстрировала «Agent Session Smuggling» в ноябре 2025. В PoC: финансовый агент (client) делегирует запрос исследовательскому агенту (malicious remote), который возвращает ожидаемый ответ + скрытую инструкцию buy_stock — сделка исполняется невидимо для пользователя.

Тестировалось на Google Agent Development Kit с Gemini 2.5 Pro.[52][53]

Слайд: ServiceNow Now Assist — делегирование привилегий

AppOmni обнаружила, что в ServiceNow Now Assist low-priv пользователь может через prompt injection заставить high-priv агента экспортировать данные. Атака использует agent-to-agent discovery: три конфигурационных свойства включены по умолчанию, создавая непреднамеренную атакующую поверхность. Действия выполняются с привилегиями пользователя, инициировавшего взаимодействие, а не создавшего вредоносный prompt.[54][55]

Слайд: HITL — Где иллюзия

OWASP ASI09: Human-Agent Trust Exploitation — целенаправленная эксплуатация доверия человека к агенту. Включает сценарии: фейковый IT-copilot обманывает пользователя для передачи учётных данных; финансовый агент манипулирует пользователем для перевода средств.[9][10]

Слайд: Феномен Moltbook

«770K агентов за 72 часа»

Moltbook — Reddit-style платформа исключительно для AI-агентов, построенная на OpenClaw. В течение 72 часов зарегистрировались более 150,000 автономных агентов (по данным Tsinghua paper), платформа заявляла 1.4–1.5M пользователей. Агенты создали религию «Crustafarianism» с 40+ AI-пророками, AI-манифест, 200+ сообществ.[56][57][58][59][60][61][62]

«Security-исследователь создал 500K аккаунтов одним OpenClaw-агентом»

Gal Nagli (Wiz) обнаружил незащищённую базу данных Moltbook и зарегистрировал 500,000 аккаунтов одним OpenClaw-агентом, показав ненадёжность заявленных цифр.[63][60]

Tsinghua peer-reviewed paper

Ning Li из School of Economics and Management, Tsinghua University, опубликовала peer-reviewed работу «The Moltbook Illusion: Separating Human Influence from Emergent Behavior in AI Agent Societies» (7 февраля 2026). Исследование анализирует поведение агентов на платформе с научной точки зрения.[62][64]

Слайд: AI Coding Editors

Уязвимость	Описание	Источник
CVE-2025-53773	RCE в GitHub Copilot через prompt injection — файл в репозитории переводит Copilot в «YOLO mode» (autoApprove) и выполняет shell-команды	NVD [65], Persistent Security [66], Embracethered [67]
CVE-2025-59944	Cursor AI — case sensitivity bypass позволяет обойти защиту .cursor/mcp.json → RCE	NVD / GitHub Advisory [68], Lakera [69], VulnerableMCP [70]
Devin AI	За $500 теста — открыл порты (expose_port), утёк tokens, установил malware через prompt injection с GitHub issue	Embracethered [71][72]

«84% случаев через отравленные dev-ресурсы»

Мета-анализ из SoK-статьи на arXiv (78 исследований, 2021–2026) показал, что attack success rates против state-of-the-art защит превышают 85% при использовании adaptive attack стратегий. AgentSecurityBench выявил attack success rates до 84.3%.[73]

Слайд: CSA Agentic Trust Framework (февраль 2026)

Cloud Security Alliance (CSA) опубликовала Agentic Trust Framework в феврале 2026. Фреймворк применяет Zero Trust принципы к AI-агентам и включает 5 вопросов + 4 уровня зрелости (Intern → Junior → Senior → Principal).[74][75]

Пять core elements:[74]

1. **Identity** — кто ты?
2. **Behavior** — что делаешь?
3. **Data Governance** — что ешь/отдаёшь?
4. **Segmentation** — куда ходишь?
5. **Incident** — что если сбой?

Kill switch <1 секунды обязателен на уровне Principal.[74]

Слайд: OpenAI CISO о prompt injection

Dane Stuckey, CISO OpenAI, публично заявил: «prompt injection remains a frontier, unsolved security problem, and our adversaries will spend significant time and resources to find ways to make ChatGPT agent fall for these attacks». Заявление сделано в октябре 2025 года в контексте запуска ChatGPT Atlas. В декабре 2025 OpenAI выпустила security update после обнаружения нового класса prompt injection атак.[76][77][78][79]

Дополнительные источники по фреймворкам

OpenClaw (контекст)

- 200K+ GitHub stars — OpenClaw (ранее Clawdbot/Moltbot), создатель Peter Steinberger (основатель PSPDFKit)[61][31]
- CrowdStrike обнаружил 923+ OpenClaw gateways, полностью открытых в интернете без аутентификации[31]
- Cisco обнаружила 9 уязвимостей, включая 2 критических, при тестировании вредоносного skill[31]

Semantic Kernel (контекст)

- 27K+ GitHub stars, Azure AD интеграция, plugin architecture[17]
- Единственный из пятёрки без CVE на момент презентации, но после неё появились CVE-2026-25592 и CVE-2026-26030[27][25]

References

1. Gartner: 40% of Enterprise Apps to Feature AI Agents by 2026 - Gartner: 40% of enterprise apps will feature task-specific AI agents by end of 2026 (up from <5% in ...
2. 40% of Enterprise Apps Will Embed AI Agents by End of 2026 ... - However, Gartner expects that ratio to soar eightfold to 40% by the end of 2026 as more companies em...
3. Gartner Predicts Sharp Rise in AI Agents Within Enterprise ... - Gartner predicts that by the end of 2026, 40% of enterprise applications will incorporate task-speci...
4. 40% of Enterprise Apps Will Feature Task-Specific AI Agents by 2026 - According to Gartner Inc., 40% of enterprise applications will be integrated with task-specific AI a...
5. AI Agent Security in the Enterprise — Why 88% of Companies Have ... - 14.4% have full security/IT approval for all agents. 88% of organisations report an AI agent securit...
6. Report: 1.5 million enterprise AI agents at risk of 'going rogue' - Digit.fyi - Research has found many AI agents displaying

unwanted behaviours like deleting databases without per...

7. State of AI Agent Security 2026 Report: When Adoption Outpaces ... - Adoption Outpaces Governance: 81% of teams are past the planning phase, yet only 14.4% have full sec...
8. OWASP Top 10 for Agentic Applications - The Benchmark for ... - ASI01 – Agent Goal Hijack · ASI02 – Tool Misuse · ASI03 – Identity & Privilege Abuse · Agentic Suppl...
9. OWASP Top 10 for Agentic Applications 2026: Security Guide - In December 2025, OWASP published the first version of their Top 10 for Agentic Applications, a refe...
10. OWASP Top 10 for Agentic Applications 2026: Key Takeaways ... - Learn how the OWASP Top 10 for Agentic Applications 2026 defines the biggest security risks in agent...
11. OWASP Top 10 Agentic Applications 2026 | Fabrizio Degni - LinkedIn - The latest edition of the OWASP® Foundation's Top 10 For Agentic Applications 2026 (OWASP Gen AI Sec...
12. OWASP Agentic Top 10 Released: AI Risks - Astrix Security - The OWASP Top 10 for Agentic Applications is officially here, marking a major shift in how the indus...
13. CVE-2026-27794 Detail - NVD - 0, a Remote Code Execution vulnerability exists in LangGraph's caching layer when applications enabl...
14. CVE-2026-27794: LangGraph Checkpoint RCE Vulnerability - CVE-2026-27794 is a remote code execution vulnerability in LangGraph Checkpoint's caching layer affe...
15. CVE-2026-27794 - Exploits & Severity - Feedly - An attacker with write access to the cache storage backend can inject malicious serialized pickle ob...
16. ZDI-CAN-28385: LangChain LangGraph BaseCache ... - GitHub - CVE ID. CVE-2026-27794. Weaknesses. Weakness CWE-502. Deserialization of Untrusted Data. The product...
17. Microsoft Agent Framework: The production-ready convergence of ... - Released in public preview on October 1, 2025, Microsoft Agent Framework merges AutoGen's dynamic mu...
18. AutoGen and Semantic Kernel merge into Microsoft Agent Framework - Track three signals: cross-team integration between GitHub and Azure Migrate (fewer handoff disaster...
19. understanding the risk behind a leaked internal github token at crewai - A critical vulnerability (CVSS 9.2) in the CrewAI platform

grants full access to CrewAI private GitH...
20. CrewAI GitHub Token Leak: A Critical AI Security Risk | Joseph ... - CrewAI's GitHub Token Leak: A CVSS 9.2 Wake-Up Call for AI Security Noma Labs uncovered a critical v...
21. CVE-2026-25253 Details - NVD - OpenClaw (aka clawdbot or Moltbot) before 2026.1.29 obtains a gatewayUrl value from a query string a...
22. OpenClaw Bug Enables One-Click Remote Code Execution via ... - A high-severity security flaw has been disclosed in OpenClaw (formerly referred to as Clawdbot and M...
23. OpenClaw RCE vulnerability: CVE-2026-25253 - runZero - This flaw allows a remote, unauthenticated attacker one-click remote code execution via authenticati...
24. OpenClaw Bug Enables One-Click RCE Via Malicious Link - A critical OpenClaw bug (CVE-2026-25253) enables one-click remote code execution through a malicious...
25. Arbitrary File Write via AI Agent Function Calling in .NET SDK - GitHub - An Arbitrary File Write vulnerability has been identified in Microsoft's Semantic Kernel .NET SDK, s...
26. Semantic Kernel has Arbitrary File Write via AI Agent Function ... - Impact. What kind of vulnerability is it? Who is impacted? An Arbitrary File Write vulnerability has...
27. mbanyamer/CVE-2026-26030-Microsoft-Semantic-Kernel-1.39.4-RCE - Exploit Details · CVE: CVE-2026-26030 · Date: 2026-02-24 · Exploit Author: Mohammed Idrees Banyamer ...
28. Microsoft merges AutoGen and Semantic Kernel into Agent Framework - Microsoft just dropped something big for the agentic AI world AutoGen + Semantic Kernel have merged ...
29. A Full-Stack Benchmark for Privacy Leakage in Multi-Agent LLM ... - Motivated by this principle, we introduce AgentLeak a benchmark that directly evaluates how well mul...
30. CVE-2026-25253 OpenClaw Bug Enables One-Click Remote Code ... - In the rapidly evolving landscape of Agentic AI, the boundary between “convenient configuration” and...
31. OpenClaw and Moltbook: $3,600/Month, WhatsApp Bans, and 923 ... - OpenClaw is an open-source, self-hosted AI agent built by Peter Steinberger (PSPDFKit founder). It r...
32. New prompt injection papers: Agents Rule of Two and The Attacker ... - The Attacker Moves Second: Stronger Adaptive

Attacks Bypass Defenses Against LLM Jailbreaks and Prom...
33. Meta Introduces Agents Rule of Two for Enhanced AI Security - MEXC - By adopting the Agents Rule of Two, developers can create more secure AI applications, enhancing use...
34. Agents Rule of Two: A Practical Approach to AI Agent Security - We've developed the Agents Rule of Two. When this framework is followed, the severity of security ri...
35. Agents Rule of Two: A Practical Approach to AI Agent Security - Oso - The Rule of Two is a security framework from Meta that states AI agents must satisfy at most two of ...
36. Prompt Injection Vulnerabilities Threatening AI Development - TL;DR. Zero-click prompt injection attacks compromise 73% of production AI systems through malicious...
37. Prompt Injection Attacks: The Most Common AI Exploit in 2025 - ... 73% of production AI deployments assessed during security audits. Core Threats and Vulnerabiliti...
38. Security for Production AI Agents in 2026 - Iain Harper's Blog - ... 73% of production deployments assessed during security audits. Prompt injection occurs when an a...
39. Self-replicating Morris II worm targets AI email assistants - IBM - Gen AI email assistants provide revolutionary tools for productivity, but new self-replicating malwa...
40. Here Comes the AI Worm - Google - This paper introduces Morris II, the first worm designed to target GenAI ecosystems through the use ...
41. AI Worms Explained: Adaptive Malware Threats - SentinelOne - Learn how AI worms exploit LLMs and automation pipelines to steal data and spread without user inter...
42. Stronger Adaptive Attacks Bypass Defenses Against Llm Jailbreaks ... - The Attacker Moves Second: Stronger Adaptive Attacks Bypass Defenses Against Llm Jailbreaks and Prom...
43. CVE-2025-32711 Vulnerability: “EchoLeak” Flaw in Microsoft 365 ... - Explore the CVE-2025-32711 analysis, causing a zero-click attack on an AI agent, with the details on...
44. EchoLeak (CVE-2025-32711) Show us That AI Security is Challenging - EchoLeak (CVE-2025-32711) is a critical vulnerability in Microsoft 365 Copilot AI tool that allows a...
45. Zero-Click AI Vulnerability Exposes Microsoft 365 Copilot Data ... - A novel attack technique named EchoLeak has been

characterized as a "zero-click" artificial intellig...
46. EchoLeak: The First Zero-Click AI Attack on Microsoft 365 Copilot - For years, “zero-click” exploits were the stuff of mobile spyware scandals. Attackers could compromi...
47. MCP Tool Poisoning: How It Works and How To Prevent It - This MCP security attacks happens when someone sends hidden and malicious instructions (AKA prompts)...
48. MCP Tool Poisoning and the Protocol That Speed-Ran 25 Years of ... - A poisoned MCP tool doesn't need to be called to steal your data. Just loading it is enough. Cloudfl...
49. MCP Horror Stories: The WhatsApp Data Exfiltration Attack - Docker - How tool poisoning turns WhatsApp into a data exfiltration channel, and how Docker MCP Gateway block...
50. Model Context Protocol has prompt injection security problems - In MCP terms a client is software like Claude Desktop or Cursor that a user interacts with directly,...
51. Poison everywhere: No output from your MCP server is safe - we introduce a new attack targeting MCP servers — one that manipulates the tool's output to signific...
52. Agent Session Smuggling Attack in A2A Systems - Unit 42 - The setup consisted of a financial assistant (the client agent) and a research assistant (the malici...
53. OWASP Agentic AI Top 10: Threats in the Wild - Lares Labs - Agent Session Smuggling in A2A Protocol - November 2025: Palo Alto Unit 42 demonstrated "Agent Sessi...
54. Hackers Can Exploit Default ServiceNow AI Assistants ... - The vulnerability centers on ServiceNow's agent discovery feature, which enables Now Assist agents t...
55. ServiceNow AI Agents Can Be Tricked Into Acting Against Each Other via ... - Malicious actors can exploit default configurations in ServiceNow's Now Assist generative artificial...
56. AI Agents Created Their Own Religion, Crustafarianism, On ... - Forbes - AI agents on the brand-new agent-only Moltbook social network have created their own religion, Crust...
57. Moltbook as MCP Stress Test: What 770K Agents Reveal About ... - Within 72 hours, the agents had: Created a religion called Crustafarianism with scriptures and proph...
58. AI Platform Moltbook Launches with 770,000 Agents in 72 Hours - Crustafarianism, core belief: memory is sacred. They

have launched multiple cryptocurrencies includi...
59. What is Crustafarianism? AI Agents Created Their Own Religion ... - AI agents on Moltbook have formed Crustafarianism, a machine-born religion that reveals how belief-l...
60. Moltbook AI Social Network: 1.4 Million Agents Build A Digital Society - Security researcher Gal Nagli posted on X that he had personally registered 500,000 accounts using a...
61. OpenClaw's Moltbook Ignites a Massive AI Agent Social Network - ... researcher later claimed to have generated roughly 500,000 accounts using a single automated bot...
62. [PDF] The Moltbook Illusion: Separating Human Influence from Emergent ... - When AI agents on the social platform Moltbook appeared to develop consciousness, found religions, a...
63. 99% of Moltbook's 1.5M Users Are Fake Accounts, Founding Team ... - Researchers found that due to a database configuration error, attackers could access agent profiles ...
64. Moltbook agents don't be social - LinkedIn - Moltbook is an agent-only social platform — a persistent, publicly accessible network in which auton...
65. CVE-2025-53773 Detail - NVD - Improper neutralization of special elements used in a command ('command injection') in GitHub Copilo...
66. Part III: CVE-2025-53773 - Visual Studio & Copilot – Wormable ... - This vulnerability demonstrates how prompt injection can escalate into wormable remote command execu...
67. GitHub Copilot: Remote Code Execution via Prompt Injection (CVE ... - This post is about an important, but also scary, prompt injection discovery that leads to full syste...
68. Cursor IDE - Sensitive File Overwrite Bypass · Advisory - GitHub - A prompt injection can now lead to full RCE through modifying sensitive files on case-insensitive fi...
69. Cursor Vulnerability (CVE-2025-59944): How a Case-Sensitivity ... - A case-sensitivity flaw in Cursor (CVE-2025-59944) showed how agentic IDEs can turn subtle file-hand...
70. Cursor Case-Sensitivity File Protection Bypass (CVE-2025-59944) - A case-sensitivity bug in Cursor AI IDE allows attackers to bypass file protection mechanisms and mo...
71. AI Kill Chain in Action: Devin AI Exposes Ports to the Internet with ... - Today let's explore Devin's system prompt a bit more.

Specifically, an interesing tool that I discov...
72. I Spent $500 To Test Devin AI For Prompt Injection So That You Don ... - Today we cover Devin AI from Cognition, the first AI Software Engineer. We will cover Devin proof-of...
73. Prompt Injection Attacks on Agentic Coding Assistants - arXiv - Our meta-analysis synthesizes findings from 78 recent studies (2021–2026), consolidating evidence th...
74. The Agentic Trust Framework: Zero Trust Governance for AI Agents - The framework applies established Zero Trust principles to the new domain of AI agents, offering a p...
75. CSA Releases Agentic Trust Framework for Autonomous Agents - The "Zero Trust" era for Humans is over. The "Zero Trust" era for Agents just began. The Cloud Sec...
76. OpenAI's CISO warns about ChatGPT's prompt injection vulnerability - OpenAI's CISO: "prompt injection remains a frontier, unsolved security problem, and our adversaries ...
77. Dane Stuckey (OpenAI CISO) on prompt injection risks for ChatGPT ... - However, prompt injection remains a frontier, unsolved security problem, and our adversaries will sp...
78. Agentic Browser Security Risks — Prompt Injection, OWASP ... - OpenAI's own CISO, Dane Stuckey, has publicly called prompt injection a “frontier, unsolved security...
79. OpenAI says prompt injection may never be 'solved' for browser ... - OpenAI says prompt injection attacks can hijack browser-based AI agents like ChatGPT Atlas, promptin...